TP : analyse des données des applications Android.

Nous allons effectuer une analyse approfondie du marché des applications Android en comparant des milliers d'applications sur le Google Play Store.

Les données des applications et des avis ont été extraites du Google Play Store par Lavanya Gupta en 2018. Les fichiers originaux sont répertoriés ici. (https://www.kaggle.com/lava18/google-play-store-apps).

1. Charger les données dans une dataframe `df_apps`.
2. Combien de lignes et de colonnes contient `df_apps` ? Quels sont les noms des colonnes ? Regardez un échantillon aléatoire de 5 lignes différentes.
3. Supprimez les colonnes appelées Last_Updated et Android_Version du DataFrame. Nous n'utiliserons pas ces colonnes.
4. Combien de lignes ont une valeur `NaN` (not-a-number) dans la colonne `Ratings` ? imputez les valeurs manquantes et créez un DataFrame appelé `df_apps_clean`.
5. Y a-t-il des doublons dans les données ? Vérifiez les doublons en utilisant la fonction .duplicated(). Combien d'entrées pouvez-vous trouver pour l'application "Instagram" ? Utilisez .drop_duplicates() pour supprimer tous les doublons de df_apps_clean.
6. Identifiez quelles applications sont les mieux notées. Quel problème pourriez-vous rencontrer si vous vous fiez uniquement aux notes pour évaluer la qualité d'une application ?
7. Trouvez les 5 plus grandes applications en termes de taille (en Mo).
8. Quelles applications ont le plus grand nombre de critiques (Reviews) ? Y a-t-il des applications payantes parmi les 50 premières ?
9. Visualise Categorical Data: Content Ratings en utilisant Plotly Pie and Donut Charts.
10. Combien d'applications ont été installées plus d'un milliard de fois ? Combien d'applications n'ont été installées qu'une seule fois ?
    a. Vérifiez le type de données de la colonne Installs.
    b. Comptez le nombre d'applications à chaque niveau d'installation.
    c. Convertissez le nombre d'installations (colonne Installs) en un type de données numérique. Astuce : c'est un processus en deux étapes. Vous devrez d'abord vous assurer de supprimer les caractères non numériques.
11. Trouvez les applications les plus chères:
    a. Convertissez la colonne Price en données numériques. Ensuite, examinez les 20 applications les plus chères du jeu de données.
    b. Ajoutez une colonne appelée Revenue_Estimate au DataFrame. Cette colonne doit contenir le prix de l'application multiplié par le nombre d'installations.

    c. Quelles sont les 10 applications payantes les plus rentables selon cette estimation ? Parmi les 10 applications payantes les plus rentables, combien sont des jeux ?
12. Analyser les catégories d'applications (histogramme)
13. Analyser Catégories les plus populaires (avec le plus grand nombre de téléchargements). (Horizontal Bar Chart)
14. Concentration des catégories - Téléchargements vs. Concurrence:
    a. Créez un DataFrame avec les colonnes catégories, le nombre d'applications et le nombre d'installations.
    b. Utiliser scatterplot() pour visualiser le nombre d'installations en fonction nombre d'applications. Ajouter aussi les catégories.
    c. À votre avis, quelles sont les meilleures catégories que vous jugez idéales et plus rentables en termes d'argent pour développer une application.